



Université Paris Cité

Master 1 Machine Learning pour la Science des Données

Année universitaire 2025–2026

Projet Pluridisciplinaire

Text2FaceGAN

Face Generation from Fine-Grained Textual Descriptions

Encadré par :

Mme. Severine AFFELDT

Présenté par :

Mme. Rhofra ADAHCHOUR

Mme. Nourelhouda DJERIOU

Mme. Safae SEBAY

Mme. Zara ZULFIQAR

Sommaire

Introduction	2
1 État de l’art	3
1.1 Les réseaux antagonistes génératifs : principe général	3
1.2 De la synthèse d’images générales à la synthèse de visages	3
1.3 Encodeurs textuels : de Skip-Thought à BERT	4
1.4 Métriques d’évaluation des GANs	4
2 Description de l’approche	5
2.1 Le dataset CelebA et la génération automatique de captions	5
2.2 L’encodage textuel : du Skip-Thought au Sentence-BERT	5
2.3 Architecture du GAN : DCGAN conditionnel avec GAN-CLS	5
2.4 Le mécanisme de label swapping	6
2.5 Protocole d’entraînement et choix techniques	6
3 Analyse critique de l’approche	8
3.1 Points forts de Text2FaceGAN	8
3.2 Analyse des courbes d’entraînement	8
3.3 Analyse visuelle des images générées	9
3.4 Critique des métriques d’évaluation du papier	9
3.5 Ablation du label swapping	10
3.6 Limitations identifiées	10
4 Évaluations complémentaires : StackGAN	12
4.1 Motivation et présentation de StackGAN	12
4.2 Protocole expérimental	12
4.3 Analyse des courbes d’entraînement	13
4.4 Évaluation quantitative : FID	13
4.5 Évaluation qualitative des images générées	14
4.6 Tests de cohérence textuelle	15
4.7 Vérification du mode collapse	16
4.8 Comparaison Text2FaceGAN vs StackGAN	16
Conclusion	18
Bibliographie	19

Introduction

Contexte

La génération automatique de visages à partir de descriptions textuelles constitue un problème à la croisée du traitement du langage naturel et de la vision par ordinateur. Cette tâche, qui consiste à produire une image réaliste d'un visage humain à partir d'une phrase telle que « une femme aux cheveux bouclés, aux pommettes saillantes et portant du rouge à lèvres », présente des applications concrètes dans de nombreux domaines : reconstruction criminelle, jeux vidéo, accessibilité pour les personnes malvoyantes ou encore personnalisation d'avatars numériques.

Ce projet tuteuré s'inscrit dans le cadre du Master MLSD de l'Université Paris Cité et porte sur l'article *Text2FaceGAN: Face Generation from Fine Grained Textual Descriptions*, publié en 2019 par Nasir et al. du laboratoire MIDAS de l'IIT-Delhi. Ce travail est l'un des premiers à s'attaquer spécifiquement au problème de la synthèse de visages conditionnée sur des descriptions textuelles fines, en s'appuyant sur le dataset CelebA et sur une architecture de réseau antagoniste génératif conditionnel.

Problématique

Notre travail s'organise en plusieurs axes complémentaires. Nous avons d'abord reproduit les résultats du papier original en réimplémentant l'architecture en PyTorch, en remplaçant l'encodeur textuel Skip-Thought par Sentence-BERT pour des raisons de faisabilité pratique. Nous avons ensuite mené une étude d'ablation sur le mécanisme de label swapping proposé par les auteurs, puis évalué les résultats à l'aide de métriques complémentaires telles que le FID. En parallèle, nous avons exploré StackGAN comme alternative architecturale permettant de dépasser certaines limitations fondamentales de l'approche originale, notamment en termes de résolution et de qualité visuelle.

Méthodologie

Ce rapport présente successivement l'état de l'art dans le domaine de la génération d'images conditionnée sur le texte, puis décrit en détail l'approche reproduite et les choix techniques opérés. Nous proposons ensuite une analyse critique des forces et limites de Text2FaceGAN, avant de présenter nos évaluations complémentaires fondées sur l'architecture StackGAN et leurs résultats.

Chapter 1

État de l'art

1.1 Les réseaux antagonistes génératifs : principe général

Avant d'aborder la génération d'images à partir de texte, il est nécessaire de comprendre le mécanisme fondamental sur lequel repose l'ensemble des travaux présentés dans ce rapport : les Generative Adversarial Networks, ou GANs. Introduits par Ian Goodfellow et ses collaborateurs en 2014, les GANs représentent une rupture majeure dans le domaine de la modélisation générative.

Un GAN est un système composé de deux réseaux de neurones entraînés simultanément en opposition l'un contre l'autre. Le premier réseau, appelé générateur (G), a pour mission de produire des données synthétiques dans notre cas, des images de visages à partir d'un vecteur de bruit aléatoire prélevé dans un espace latent. Le second réseau, le discriminateur (D), agit comme un juge : il reçoit soit une image réelle issue du dataset, soit une image produite par le générateur, et doit déterminer laquelle est vraie et laquelle est fausse. Ces deux réseaux s'engagent dans un jeu minimax : le générateur cherche à tromper le discriminateur en produisant des images de plus en plus réalistes, tandis que le discriminateur s'améliore continuellement pour ne plus se laisser abuser.

Formellement, le générateur G apprend une fonction de transformation $G: z \rightarrow x$, où z est un vecteur de bruit et x une image synthétique. L'équilibre théorique de ce jeu, dit équilibre de Nash, est atteint lorsque les images produites par G sont statistiquement indiscernables des données réelles. L'une des variantes les plus importantes pour notre projet est le GAN conditionnel, ou cGAN, qui conditionne la génération sur une information auxiliaire dans notre cas, l'encodage d'une description textuelle.

1.2 De la synthèse d'images générales à la synthèse de visages

Les premiers travaux sur la génération d'images à partir de texte ont principalement porté sur des objets simples et bien définis. Reed et al. (2016) ont proposé le GAN-CLS, capable de produire des images 64×64 de fleurs ou d'oiseaux à partir de descriptions en langage naturel. Pour dépasser la contrainte de résolution, Zhang et al. ont proposé en 2017 le StackGAN, une architecture à deux étages : le premier génère une image basse résolution (64×64) capturant la structure générale, le second la raffine en 256×256 .

Cette approche progressive a constitué une avancée significative, et constitue précisément l’extension architecturale que nous explorons dans ce projet.

La génération spécifique de visages à partir de texte est un problème plus difficile. Les datasets de visages disponibles : LFW, MegaFace, CelebA n’étaient pas accompagnés de descriptions textuelles. La seule exception, Face2Text, ne contenait que 400 paires image-texte, insuffisant pour entraîner un GAN de manière stable. C’est dans ce contexte que Text2FaceGAN apporte sa contribution principale : générer automatiquement des captions pour les 202 000 images de CelebA.

1.3 Encodeurs textuels : de Skip-Thought à BERT

La qualité de la génération conditionnée sur le texte dépend fortement de la représentation textuelle utilisée. L’article Text2FaceGAN utilise les Skip-Thought vectors (Kiros et al., 2015), basés sur un encodeur-décodeur RNN qui produit des vecteurs de dimension 4800. Cependant, ces poids sont devenus inaccessibles et incompatibles avec les environnements modernes.

Dans notre reproduction, nous avons utilisé Sentence-BERT (all-MiniLM-L6-v2, 384 dimensions), et notre extension StackGAN utilise BERT (bert-base-uncased, 768 dimensions). Les deux encodeurs reposent sur l’architecture transformer introduite par Devlin et al. en 2018, qui utilise un mécanisme d’attention bidirectionnelle surpassant systématiquement les approches RNN pour la compréhension du langage naturel. Le papier original suggère lui-même ce remplacement dans sa section de perspectives.

1.4 Métriques d’évaluation des GANs

L’*Inception Score* (IS), proposé par Salimans et al. en 2016, mesure simultanément la clarté et la diversité des images générées via un classifieur InceptionV3 pré-entraîné. Cependant, ce classifieur n’est pas adapté aux visages humains, qui ne correspondent à aucune catégorie d’ImageNet, ce que les auteurs reconnaissent eux-mêmes dans le papier.

Le FID (*Fréchet Inception Distance*), proposé par Heusel et al. en 2017, constitue la métrique de référence actuelle. Il compare la distance statistique de Fréchet entre les distributions des features InceptionV3 extraites des images réelles et générées. Un FID bas indique une distribution générée proche des données réelles. Contrairement à l’IS, le FID compare explicitement images réelles et générées, ce qui le rend bien plus robuste et corrélé à la perception humaine.

Chapter 2

Description de l'approche

2.1 Le dataset CelebA et la génération automatique de captions

Le dataset CelebA (*Large-scale CelebFaces Attributes*) contient 202 599 images de visages de célébrités, accompagnées de 40 attributs binaires par image. L'une des contributions principales du papier Text2FaceGAN est la création d'un algorithme permettant de convertir automatiquement ces attributs en captions en langage naturel, organisées en six groupes thématiques : structure du visage, pilosité faciale, coiffure, caractéristiques faciales, apparence générale et accessoires.

Voici un exemple de caption générée : « *The woman has high cheekbones. She has straight hair which is brown in colour. She has pointy nose with arched eyebrows. The smiling, young attractive woman has heavy makeup. She is wearing earrings and lipstick.* » Pour notre reproduction, nous avons utilisé le fichier `caps.txt` mis à disposition par les auteurs (192 050 captions), en sélectionnant 10 000 images avec un split 7 500 / 2 500 conforme au protocole du papier.

2.2 L'encodage textuel : du Skip-Thought au Sentence-BERT

Dans le papier original, les captions sont encodées à l'aide de Skip-Thought (4800 dimensions) puis réduites à 256 dimensions. Pour notre reproduction, nous avons utilisé Sentence-BERT *all-MiniLM-L6-v2* (384 dimensions) pour trois raisons : inaccessibilité des poids Skip-Thought, meilleure performance des architectures transformer, et suggestion explicite de ce remplacement par les auteurs dans leurs perspectives. L'encodage des 192 050 captions a été réalisé sur CPU en environ 15 minutes, les vecteurs étant sauvegardés en cache.

2.3 Architecture du GAN : DCGAN conditionnel avec GAN-CLS

Le générateur reçoit un vecteur de bruit z (100d) et un embedding textuel réduit (256d), concaténés en un vecteur de 356 dimensions projeté vers un tenseur $512 \times 4 \times 4$. Quatre couches déconvolutionnelles progressivement upsamplent ce tenseur jusqu'à une image RGB 64×64 . Le discriminateur suit une architecture miroir avec quatre couches con-

volutionnelles, injection du texte sur le feature map $4 \times 4 \times 512$, et une couche finale sigmoïde.

La perte GAN-CLS impose au discriminateur d'évaluer trois types de paires :

- (*image réelle, bonne caption*) $\rightarrow$ vraie ;
- (*image réelle, mauvaise caption*) $\rightarrow$ fausse ;
- (*image générée, bonne caption*) $\rightarrow$ fausse.

Cette formulation force la vérification de la cohérence texte-image, et non plus seulement la qualité visuelle isolée.

2.4 Le mécanisme de label swapping

Pour stabiliser l'entraînement et éviter que le discriminateur ne converge trop rapidement, les auteurs introduisent un *label swapping* : tous les trois batches, les étiquettes des images réelles et générées sont échangées lors de la mise à jour du discriminateur. Ce mécanisme ralentit délibérément l'apprentissage du discriminateur, laissant au générateur le temps de progresser. Notre étude d'ablation confirme expérimentalement son utilité.

2.5 Protocole d'entraînement et choix techniques

L'entraînement a été réalisé sur la plateforme Kaggle (GPU T4, 15 Go VRAM). Le tableau 2.1 récapitule les hyperparamètres utilisés.

Table 2.1: Comparaison des hyperparamètres entre le papier original et notre reproduction.

Composant	Papier original	Notre reproduction
Encodeur texte	Skip-Thought (4800d)	Sentence-BERT (384d)
Architecture	DCGAN + GAN-CLS	DCGAN + GAN-CLS
Résolution	64×64 pixels	64×64 pixels
Paramètres G	$\sim 5,8\text{M}$ (estimé)	5 780 608
Paramètres D	$\sim 3,2\text{M}$ (estimé)	3 258 369
Epochs	200	200
Batch size	64	64
lr Générateur	0,0002	0,0002
lr Discriminateur	0,0001	0,0001
Optimiseur	Adam ($\beta_1 = 0,5$)	Adam ($\beta_1 = 0,5$)
Label swap	Tous les 3 batches	Tous les 3 batches
Dataset	CelebA (10 000 img)	CelebA (10 000 img)

La principale différence technique est l'encodeur textuel. Tous les autres hyperparamètres ont été reproduits à l'identique. L'implémentation a été entièrement réécrite en PyTorch, le papier original ayant été développé sous TensorFlow 1.x, désormais obsolète.

Chapter 3

Analyse critique de l'approche

3.1 Points forts de Text2FaceGAN

Text2FaceGAN présente plusieurs contributions réelles. La première est la création du dataset d'annotation automatique : en convertissant les attributs binaires de CelebA en captions, les auteurs ont résolu le problème fondamental du manque de données pour ce problème. La seconde contribution notable est le mécanisme de label swapping, qui rend l'entraînement plus stable. Les auteurs ont également eu l'honnêteté intellectuelle de soulever eux-mêmes les limites de l'*Inception Score* comme métrique d'évaluation. Enfin, le cadre zero-shot, qui permet de générer des visages à partir de descriptions jamais vues à l'entraînement, est particulièrement ambitieux.

3.2 Analyse des courbes d'entraînement

La figure 3.1 présente les courbes de perte du générateur et du discriminateur sur 200 epochs.




Figure 3.1: Courbes de perte du générateur (orange) et du discriminateur (bleu) sur 200 epochs.

La perte du discriminateur commence à environ 3,0 puis décroît pour se stabiliser autour de 1,4;1,5 après une cinquantaine d'epochs. La perte du générateur se stabilise dans une plage de 0,75 à 0,90 à partir d'une vingtaine d'epochs. L'absence d'oscillations violentes ou de divergence confirme que le mécanisme de label swapping joue bien son rôle stabilisateur.

3.3 Analyse visuelle des images générées

La figure 3.2 illustre l'évolution de la qualité des images au cours de l'entraînement.



Figure 3.2: Évolution de la qualité des images générées de l'époque 1 à l'époque 200.

À l'époque 1, le générateur produit du bruit pur. Dès l'époque 40, des visages reconnaissables apparaissent, avec des teintes de peau, des cheveux et des yeux identifiables. La qualité s'améliore progressivement jusqu'à l'époque 200, bien que les images restent floues en raison de la faible résolution de 64×64 pixels.




Figure 3.3: Génération en mode zero-shot sur 8 captions non vues à l'entraînement.

Ces résultats zero-shot confirment la capacité de généralisation du modèle : les captions féminines produisent des visages féminins, les captions masculines des visages masculins. La correspondance fine sur les attributs reste cependant difficile à évaluer à 64×64 pixels.

3.4 Critique des métriques d'évaluation du papier

Le papier original rapporte un IS de $1,4 \pm 0,7$. Notre reproduction obtient un score similaire. Le tableau 3.1 résume les résultats quantitatifs.

Table 3.1: Résultats quantitatifs de la reproduction et comparaison aux références.

Métrique	Valeur obtenue	Référence	Interprétation
IS (papier)	$1,4 \pm 0,7$	—	Inadapté aux visages
FID (nôtre)	138,99	< 100 bon, < 200 moyen	Cohérent avec 10k images

L'IS est peu informatif pour cette tâche : InceptionV3 n'a pas de catégorie dédiée aux visages humains, et la distribution des classes sera quasi-uniforme quelle que soit la qualité des images. Notre FID de 138,99 est cohérent avec les contraintes expérimentales (10 000 images, 64×64 pixels) et traduit une distance encore significative entre la distribution des images générées et celle des images réelles.

3.5 Ablation du label swapping

Un second modèle identique a été entraîné 50 epochs sans le label swapping, pour quantifier son effet.




Figure 3.4: Ablation du label swapping sur 50 epochs. Bleu : avec swap (papier). Rouge pointillés : sans swap.

Sans swap, la perte du générateur présente une instabilité significative dans les premières epochs (pic à 2,2) et des oscillations persistantes entre 1,0 et 1,5 sur 50 epochs. Avec swap, le générateur atteint rapidement une plage de stabilité entre 0,75 et 1,0. Ces résultats confirment expérimentalement l'utilité du mécanisme, même si les deux modèles convergent finalement vers des pertes similaires.

3.6 Limitations identifiées

Trois limitations fondamentales de l'approche méritent d'être soulignées. La première est la résolution de 64×64 pixels, insuffisante pour capturer les détails fins d'un visage humain. La deuxième est le volume de données limité à 10 000 images sur les 202 599

disponibles dans CelebA. La troisième, et la plus fondamentale, est architecturale : le DC-GAN monostade de 2019 est dépassé par les approches modernes. C'est cette observation qui nous a motivés à explorer StackGAN dans la partie suivante.

Chapter 4

Évaluations complémentaires : StackGAN

4.1 Motivation et présentation de StackGAN

Face aux limitations identifiées dans l’analyse critique c’est-à-dire : résolution insuffisante, architecture monostade dépassée, nous avons choisi d’explorer StackGAN (Zhang et al., ICCV 2017) comme évaluation complémentaire principale. StackGAN apporte deux améliorations architecturales fondamentales par rapport à Text2FaceGAN : une génération en deux étages progressifs permettant d’atteindre une résolution de 128×128 pixels, et l’utilisation de BERT comme encodeur textuel offrant une compréhension sémantique bien supérieure à Skip-Thought.

Le Stage-I de StackGAN génère une image 64×64 capturant les grandes structures et les couleurs cohérentes avec la description. Le Stage-II prend cette image basse résolution comme entrée supplémentaire et la raffine pour produire une image 128×128 avec des détails significativement plus fins. Cette architecture progressive est directement inspirée par les suggestions d’extension de la section VI de Text2FaceGAN, qui identifie explicitement l’augmentation de résolution (128×128 et 256×256) comme perspective prioritaire.

4.2 Protocole expérimental

Le modèle StackGAN a été entraîné sur CelebA avec les captions générées automatiquement à partir des attributs. L’encodeur textuel est BERT (*bert-base-uncased*, 768 dimensions), avec un module de Conditional Augmentation qui projette les embeddings BERT dans un espace gaussien de dimension 128 pour le conditionnement des générateurs. Le Stage-I a été entraîné pendant 150 epochs sur des images 64×64 , le Stage-II pendant 60 epochs sur des images 128×128 . Les générateurs comptent respectivement 10,25M et 26,21M de paramètres. L’évaluation repose sur le FID calculé sur 500 paires d’images réelles et générées.

4.3 Analyse des courbes d'entraînement

La figure 4.1 présente les courbes de perte des deux stages ainsi qu'une comparaison Stage-I vs Stage-II.




Figure 4.1: Courbes de perte StackGAN. Haut gauche : Stage-I train (150 epochs). Haut droit : Stage-II train (60 epochs). Bas centre : comparaison Stage-I vs Stage-II. Bas droit : pertes finales ($D_{S1}=0,042$, $G_{S1}=5,201$, $D_{S2}=0,069$, $G_{S2}=4,003$).

L'analyse de ces courbes révèle un comportement notablement différent de celui observé sur le DCGAN de Text2FaceGAN. La perte du discriminateur converge très rapidement vers des valeurs proches de zéro pour les deux stages ($D_{S1}=0,042$, $D_{S2}=0,069$), traduisant une domination rapide du discriminateur sur le générateur. En contrepartie, la perte du générateur reste élevée et continue d'augmenter tout au long de l'entraînement ($G_{S1}=5,201$, $G_{S2}=4,003$), bien au-dessus de l'équilibre théorique de Nash (0,693).

Ce déséquilibre entre discriminateur et générateur est caractéristique des GANs entraînés sans mécanisme de régulation suffisant et c'est précisément le problème que le label swapping de Text2FaceGAN cherchait à adresser. Malgré cet indicateur préoccupant au niveau des pertes, les résultats visuels et quantitatifs montrent que le modèle parvient néanmoins à apprendre une distribution cohérente, probablement grâce à la richesse de l'encodeur BERT et à la capacité accrue des générateurs StackGAN.

4.4 Évaluation quantitative : FID

La figure 4.2 présente les scores FID obtenus pour les deux stages de StackGAN.




Figure 4.2: FID Score StackGAN. Stage-I (64×64) : 74,21. Stage-II (128×128) : 79,72. Les deux scores se situent dans la plage « Bon » (< 100).

StackGAN obtient un FID de 74,21 pour le Stage-I (64×64) et de 79,72 pour le Stage-II (128×128). Ces scores se situent tous deux dans la plage « Bon » selon les standards de la littérature (< 100), et représentent une amélioration significative par rapport au FID de 138,99 obtenu par notre reproduction de Text2FaceGAN. Le fait que le Stage-II présente un FID légèrement plus élevé que le Stage-I (79,72 vs 74,21) est contre-intuitif mais s'explique par plusieurs facteurs : la tâche de raffinement est plus difficile, le Stage-II est entraîné moins longtemps (60 epochs vs 150), et la distribution des images 128×128 de référence est intrinsèquement plus difficile à reproduire.

La progression depuis Text2FaceGAN (FID 138,99) vers StackGAN Stage-I (74,21) représente une réduction de 46% du FID, confirmant quantitativement l'apport de l'architecture à deux stages et de l'encodeur BERT pour la génération de visages conditionnée sur le texte.

4.5 Évaluation qualitative des images générées

La figure 4.3 présente une comparaison directe Stage-I vs Stage-II sur 8 descriptions de test couvrant des profils variés.




Figure 4.3: Stage-I (64×64) vs Stage-II (128×128) sur 8 descriptions de test. Ligne du haut : Stage-I. Ligne du bas : Stage-II. De gauche à droite : femme brune, homme noir, femme blonde, homme barbu, femme lunettes, homme jeune, femme frange, homme chauve.

La comparaison visuelle entre les deux stages est éloquent. Les images Stage-II (128×128)

présentent une netteté nettement supérieure aux images Stage-I (64×64), avec des détails de texture de peau, des contours de cheveux et des traits du visage significativement plus précis. On note également que Stage-II produit des images avec des fonds légèrement bruités ou colorés. C'est un artefact classique des GANs qui concentrent leur capacité sur la génération du visage au détriment de l'arrière-plan.

Sur le plan de la cohérence textuelle, le modèle montre des résultats encourageants : la différenciation homme/femme est clairement observable, la couleur des cheveux est généralement respectée (cheveux noirs pour « black in colour », blonds pour « blond in colour »), et certains attributs distinctifs comme la barbe ou la calvitie sont visibles dans les images correspondantes. Le modèle reste cependant imparfait sur les attributs fins comme la forme exacte du visage ou la présence d'accessoires discrets.

4.6 Tests de cohérence textuelle

Pour évaluer précisément la cohérence entre les descriptions textuelles et les images générées, nous avons conduit des tests de variation d'attribut : un seul attribut change entre les descriptions, tous les autres restant constants.




Figure 4.4: Tests de cohérence — variation d'un attribut à la fois. Ligne 1 : couleur cheveux (noirs, blancs, bruns, gris). Ligne 2 : genre (femme, homme). Ligne 3 : style cheveux (ondulés, raides, frange, chauve). Ligne 4 : accessoires (lunettes, chapeau, cravate, aucun).

Ces tests révèlent des résultats contrastés selon les catégories d'attributs. La variation de couleur de cheveux est bien capturée : les quatre images produites pour noirs, blonds, bruns et gris montrent des variations de teinte clairement discernables. La variation de genre (femme vs homme) est également bien gérée, avec des différences morphologiques faciales visibles. En revanche, la variation de style de cheveux (ondulés vs raides vs frange vs chauve) est moins précise : si la calvitie est bien représentée, les distinctions entre ondulés et raides restent subtiles.

Les tests sur les accessoires montrent les limites les plus prononcées : les lunettes sont partiellement visibles mais peu précises, le chapeau est rarement bien rendu, et la cravate est presque absente des images générées. Ce résultat est cohérent avec la littérature : les accessoires constituent des détails fins que les GANs à résolution modérée reproduisent difficilement, nécessitant des mécanismes d'attention spécialisés comme AttnGAN pour être correctement traités.

4.7 Vérification du mode collapse

Pour confirmer l'absence de mode collapse, nous avons généré 16 images à partir de la même description avec 16 vecteurs de bruit différents.




Figure 4.5: Vérification du mode collapse : 16 images générées pour la même description avec 16 seeds différents. Variance pixel = 0,0224 ($> 0,01$ = OK). Distance L2 moyenne = 45,61.

Les 16 images présentent une diversité visuelle claire : poses légèrement différentes, variations d'expression, nuances de texture et d'éclairage. La variance pixel de 0,0224, supérieure au seuil de 0,01 généralement retenu comme indicateur d'absence de mode collapse, confirme que le générateur explore bien l'espace des réalisations possibles plutôt que de converger vers une image unique. La distribution des distances L2 entre paires d'images, avec une moyenne de 45,61 et une dispersion continue, confirme cette diversité.

4.8 Comparaison Text2FaceGAN vs StackGAN

Le tableau 4.1 synthétise les résultats obtenus par les deux approches sur l'ensemble des critères d'évaluation.

Table 4.1: Comparaison complète Text2FaceGAN vs StackGAN sur l’ensemble des critères.

Métrique / Critère	DCGAN (papier)	DCGAN (nôtre)	StackGAN (ext.)
FID	N/R	138,99	74,21 (S1) / 79,72 (S2)
IS	$1,4 \pm 0,7$	$\sim 1,4$	N/R (inadapté)
Résolution	64×64	64×64	$64 \times 64 + 128 \times 128$
Encodeur texte	Skip-Thought	Sentence-BERT	BERT (768d)
Paramètres G	$\sim 5,8\text{M}$	5,8M	10,25M + 26,21M
Mode collapse	Non (papier)	Non ✓	Non ✓ (var=0,0224)
Qualité visuelle	Floue (64×64)	Floue (64×64)	Nette (128×128)

La comparaison quantitative et qualitative établit clairement la supériorité de StackGAN sur Text2FaceGAN pour la tâche de génération de visages conditionnée sur du texte. La réduction de FID de 138,99 à 74,21 (-46%) confirme que l’architecture à deux stages, combinée à un encodeur textuel BERT plus puissant, permet d’apprendre une distribution d’images significativement plus proche des données réelles. La résolution doublée (128×128 vs 64×64) offre un gain qualitatif majeur, bien perceptible dans les analyses visuelles.

Il convient cependant de nuancer cette comparaison. Les courbes d’entraînement de StackGAN révèlent un déséquilibre discriminateur/générateur plus prononcé que dans Text2FaceGAN, suggérant que l’architecture StackGAN bénéficierait d’un mécanisme de régulation similaire au label swapping du papier original. Par ailleurs, les deux approches partagent les mêmes limites concernant la cohérence sur les attributs fins (accessoires, style de cheveux précis), ce qui pointe vers le besoin de mécanismes d’attention plus sophistiqués comme AttnGAN pour les traitements futurs.

En conclusion de cette évaluation complémentaire, StackGAN représente une extension naturelle et efficace de Text2FaceGAN qui adresse directement ses deux principales limitations : la résolution insuffisante et l’encodeur textuel obsolète. Les résultats obtenus confirment que la génération de visages conditionnée sur du texte à partir d’une architecture à deux stages entraînée sur CelebA constitue une approche viable et prometteuse.

Conclusion

Ce projet a conduit une étude complète de Text2FaceGAN, depuis l’analyse critique de l’article original jusqu’à la réimplémentation intégrale du modèle et l’exploration d’une extension architecturale majeure via StackGAN.

L’analyse de l’article a mis en évidence la pertinence de la contribution dans son contexte : l’adaptation de GAN-CLS au domaine des visages humains, avec génération automatique de descriptions par supervision faible, constitue une approche élégante au problème de la génération conditionnelle fine-grained. Le mécanisme de label swapping adresse directement le défi de la stabilité d’entraînement adversarial, et notre étude d’ablation confirme expérimentalement son efficacité. La critique honnête de l’*Inception Score* par les auteurs eux-mêmes témoigne d’une rigueur scientifique méritoire.

La phase de reproduction a validé la fidélité de notre réimplémentation en PyTorch, avec un FID de 138,99 cohérent avec les contraintes expérimentales. L’évaluation qualitative confirme les capacités zero-shot du modèle et l’absence de mode collapse. Notre remplacement de Skip-Thought par Sentence-BERT constitue une contribution technique justifiée par les suggestions des auteurs et les contraintes de reproductibilité modernes.

L’évaluation complémentaire via StackGAN constitue la contribution principale de notre projet. Avec un FID de 74,21 pour le Stage-I et 79,72 pour le Stage-II, soit une réduction de 46% par rapport à Text2FaceGAN, et des images générées à 128×128 pixels nettement plus détaillées, StackGAN démontre concrètement comment les limitations identifiées dans le papier original peuvent être adressées. Les tests de cohérence textuelle révèlent des forces (couleur de cheveux, genre) et des limites (accessoires fins, styles de cheveux précis) qui orientent naturellement vers des perspectives futures telles qu’AttnGAN ou les modèles de diffusion.

Ce projet illustre plus généralement la dynamique de progrès rapide dans le domaine de la génération d’images conditionnée sur le texte : une architecture proposée en 2019 peut être significativement améliorée en adoptant des composants plus récents (BERT, génération progressive) sans modification fondamentale du paradigme GAN conditionnel. Les modèles de diffusion comme Stable Diffusion représentent la frontière actuelle de ce domaine, avec des capacités de génération photoréaliste que les architectures GAN présentées ici ne peuvent pas encore égaler à résolution et données comparables.

Bibliographie

1. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative Adversarial Nets. *Advances in Neural Information Processing Systems*, 27.
2. Nasir, O. R., Jha, S. K., Grover, M. S., Yu, Y., Kumar, A., & Shah, R. R. (2019). Text2FaceGAN: Face Generation from Fine Grained Textual Descriptions. *arXiv:1911.11378*.
3. Reed, S., Akata, Z., Yan, X., Logeswaran, L., Schiele, B., & Lee, H. (2016). Generative Adversarial Text to Image Synthesis. *ICML 2016*.
4. Zhang, H., Xu, T., Li, H., Zhang, S., Wang, X., Huang, X., & Metaxas, D. N. (2017). StackGAN: Text to Photo-realistic Image Synthesis with Stacked Generative Adversarial Networks. *ICCV 2017*.
5. Xu, T., Zhang, P., Huang, Q., Zhang, H., Gan, Z., Huang, X., & He, X. (2018). AttnGAN: Fine-Grained Text to Image Generation with Attentional GAN. *CVPR 2018*.
6. Kiros, R., Zhu, Y., Salakhutdinov, R., Zemel, R., Urtasun, R., Torralba, A., & Fidler, S. (2015). Skip-Thought Vectors. *Advances in Neural Information Processing Systems*, 28.
7. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *arXiv:1810.04805*.
8. Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *EMNLP 2019*.
9. Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., & Chen, X. (2016). Improved Techniques for Training GANs. *Advances in Neural Information Processing Systems*, 29.
10. Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., & Hochreiter, S. (2017). GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium. *NeurIPS*, 30.
11. Liu, Z., Luo, P., Wang, X., & Tang, X. (2015). Deep Learning Face Attributes in the Wild. *ICCV 2015*.
12. Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised Representation Learn-

- ing with Deep Convolutional GANs. *arXiv:1511.06434*.
13. Mirza, M., & Osindero, S. (2014). Conditional Generative Adversarial Nets. *arXiv:1411.1784*.
 14. Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., & Sutskever, I. (2021). Learning Transferable Visual Models From Natural Language Supervision. *ICML 2021*.